iDATA
Advanced analytics for business

PRESENTA A

BANCO DE DESARROLLO
DE AMÉRICA LATINA

DOCUMENTO DE ARQUITECTURA IFISCAF

HISTORIAL DE VERSIONES DEL DOCUMENTO

Versión	Responsable	Modificación	Fecha
V1	iDATA	Creación de documento	24/09/2024

Nombre del cliente	CAF
Nombre del proyecto	IFICAF
Responsable iDATA	Carlos Rene Trujillo (Data Science) Daniela Osorio Trujillo (Project Analyst) Gerardo Martin Orozco (Full Stack) Leonardo David Gonzales (Full Stack) Dany Daniel Carrillo Jara (Full Stack) Cristian Andres Vitery (Technical Leader)
Nombre del contacto del cliente	Braulio Salazar
Cargo	Technology Innovation Executive
Correo electrónico del contacto	bsalarzar@caf.com

Derechos de Autor y Confidencialidad del documento

IDATA S.A.S.
Derechos Reservados

El contenido de este documento y sus anexos se encuentran protegidos por el Derecho de Autor, y éstos son propiedad de IDATA S.A.S. y CAF, por lo anterior, se le debe brindar tratamiento de confidencial. El cliente puede usar dicha información solo con el propósito de “apoyar la administración de la solución” sin poder divulgar su contenido a terceras partes ya que contiene ideas, conceptos y metodologías con propiedad de IDATA S.A.S. La clasificación "confidencial" significa que esta información es sólo para uso de las personas a quienes está dirigida. Se requiere de la autorización expresa y escrita de IDATA S.A.S. para realizar copias totales o parciales de este documento. Esta información no puede ser utilizada por el cliente para fines diferentes a los del objetivo del documento realizado por IDATA S.A.S.

1 Contenido

Introducción 5
Objetivo 5
Alcance 5
Contexto 6
Implementación Estratégica de Portal para la Gestión Eficiente de Documentos de productos y servicios brindados por CAF 6
Descripción general del sistema que se va a construir 7
Separaciones de ambientes 7
Azure Data Lake - Arquitectura lago de datos 7
Vistas y especificación de arquitectura 8
Mapa general de la arquitectura 8
Integración de servicios 9
Staging Area 9
Procesamiento de lenguaje 10
Capa almacenamiento interacciones 11
Consideraciones de seguridad y funcionalidad 11
Costos asociados 11
Referencias 12

Introducción

Objetivo

El objetivo principal de este proyecto es desarrollar e implementar un portal web que brinde apoyo para CAF. Este portal se basará en Azure App Service y la tecnología de inteligencia artificial, con el fin de proporcionar asistencia a los empleados en asuntos relacionados con información de los diferentes productos de CAF de manera eficiente y efectiva, respondiendo preguntas relacionadas con el contenido de los documentos proporcionados.

Alcance

- Desarrollar e implementar una arquitectura sólida en Microsoft Azure para respaldar la solución de portal.
- Utilizar servicios clave de Azure, como Azure App Service para la implementación del portal, Azure Storage para la gestión de documentos, facilitar la integración con OpenAI, y almacenar todos los outputs, producto de la interacción con el portal, de forma organizada en el servicio de Azure Cosmos DB.
- Proporcionar una descripción completa de los componentes de la arquitectura, incluyendo la interacción entre Azure App Service, Azure Storage, OpenAI y Cosmos DB.

Contexto

Implementación Estratégica de Portal para la Gestión Eficiente de Documentos de productos y servicios brindados por CAF

CAF se encuentra actualmente inmerso en el despliegue de un portal diseñado para la gestión de documentos que contienen información sobre sus diferentes proyectos. El objetivo principal de esta iniciativa es mejorar la eficiencia y accesibilidad a la información para el área encargada analizar los diferentes proyectos financiados por CAF, convirtiéndolo en una herramienta clave que acompañe a los ejecutivos a nivel informativo y de toma de decisiones.

Para esto, se tiene previsto llevar a cabo una implementación de la arquitectura con los siguientes focos principales:

- **Proceso de Ingesta de Documentos:** Se establecerá un proceso para la ingestión de documentos relevantes, para darle al portal la capacidad de realizar consultas sobre estos, con base en las preguntas de negocio. Esto incluirá la preparación de conjuntos de datos específicos que permitan al modelo de inteligencia artificial aprender de manera efectiva sobre la terminología y contenido particular de los documentos de CAF.
- **Azure App Service como Entorno Principal:** Se priorizará la implementación de Azure App Service como el entorno de ejecución principal para el portal. Esto garantizará una infraestructura escalable y de alta disponibilidad, facilitando la interacción rápida y eficiente para CAF.
- **Interfaz de Usuario Intuitiva y Amigable:** Se pondrá especial énfasis en el diseño y desarrollo de una interfaz de usuario intuitiva y amigable. Esto permitirá una interacción fluida a los ejecutivos y el portal, mejorando la experiencia de usuario y fomentando la adopción efectiva de la herramienta.
- **Integración con OpenAI:** Se priorizará la integración con OpenAI para garantizar respuestas contextualmente relevantes y especializadas. Se explorará la capacidad de GPT-4o para comprender el lenguaje natural y proporcionar soluciones más precisas a las consultas específicas sobre documentos internos de CAF.

- **Almacenamiento de interacciones con Cosmos DB:** Todas las interacciones que el usuario pueda tener con el portal serán almacenadas en el servicio de Azure Cosmos DB para su posterior análisis. Se utilizarán contenedores para dividir la información dentro de la Cosmos DB, estos son:

Descripción general del sistema que se va a construir

Con base en las necesidades específicas de CAF, se ha planificado implementar una interfaz que siga buenas prácticas de arquitectura y desarrollo, funcionando como una solución en la nube de Azure.

Separaciones de ambientes

En el contexto de POC el desarrollo se realizará en un ambiente controlado dev con configuración de ramas main para el paso a producción y dev en Devops para el manejo correcto de las modificaciones de código.
Aunque en esta fase de creación de nuevas funcionalidades no se llevarán a cabo separaciones de ambientes, es importante destacar que, como parte de los pasos a seguir recomendados, se sugiere considerar la implementación de separaciones de ambientes en fases posteriores del proyecto. La separación de ambientes, como entornos de desarrollo, pruebas y producción, es una práctica recomendada en el ciclo de vida del desarrollo de software.

La implementación de separaciones de ambientes proporciona varios beneficios, como la mitigación de riesgos, la posibilidad de realizar pruebas exhaustivas en un entorno controlado antes de la implementación en producción, y la capacidad de desarrollar y probar nuevas funcionalidades sin afectar el entorno de producción en tiempo real.

Azure Data Lake - Arquitectura lago de datos

En la implementación del lago de datos, se ha establecido una estructura organizativa que segmenta archivos según su estado, permitiendo una gestión eficiente de documentos internos. Esta función se encarga de leer el archivo, subdividirlo en archivos más pequeños según subtemas o información puntual estas porciones del documento original son almacenadas en el contenedor y posteriormente se pueden realizar consultas desde el portal sobre la documentación cargada. De esta manera, la arquitectura facilita la consulta eficiente de datos

segmentados y optimiza la gestión documental.

Vistas y especificación de arquitectura

Mapa general de la arquitectura

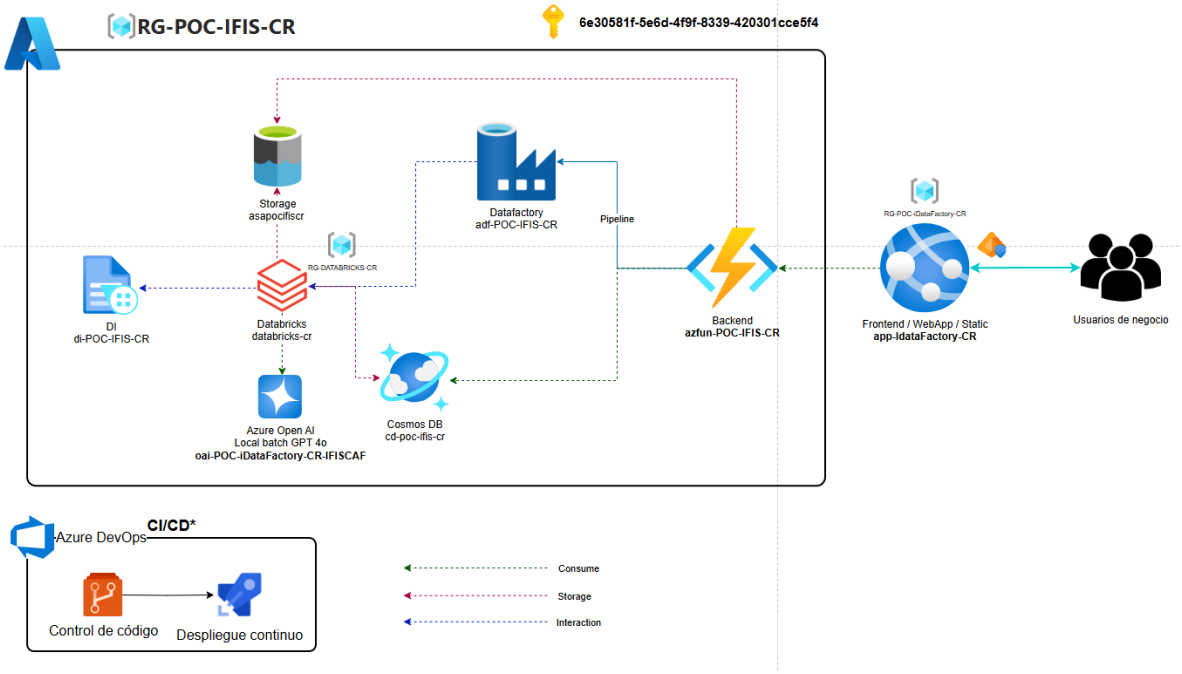

Figura 1: Diagrama de arquitectura.

El diagrama anterior ilustra el ecosistema de herramientas y servicios esenciales que serán necesarios para la implementación de una arquitectura basada en la Nube de Azure. En este entorno, se destaca la integración de servicios clave como Azure App Service para la ejecución de la app, Azure DevOps para la gestión del ciclo de vida del desarrollo, Azure Storage para el almacenamiento eficiente de datos, OpenAI para aprovechar capacidades avanzadas en procesamiento de lenguaje natural e inteligencia artificial y Azure Cosmos DB para llevar un registro dinámico y de fácil acceso de todas las interacciones que los usuarios. Este conjunto de herramientas y servicios proporciona una base sólida para la creación y evolución exitosa de la solución, asegurando la eficiencia y la adaptabilidad.

Integración de servicios

- **Service App (app-POC-iDataFactory-CR):** Es un servicio en la nube de Microsoft Azure que permite crear, hospedar y escalar aplicaciones web y APIs de manera sencilla. Al ser una plataforma administrada, se encarga de aspectos como el aprovisionamiento de recursos, escalabilidad automática, administración del sistema operativo y seguridad. Esto permite a los desarrolladores centrarse en la creación de la aplicación sin preocuparse por la infraestructura subyacente.

  Usuarios funcionales quienes interactúan con la interfaz web desplegada en el servicio de app service de la solución, cabe aclarar que si dicho usuario es técnico es posible que pueda interactuar directamente con las apis desplegadas en el servicio de Azure función.

  Servicio que aloja la interfaz web que facilita el cargue de documentos y la visualización de los resultados en la extracción de la información La web app se encargará de enviar y recibir información del proceso realizado directamente hacia y desde las APIs disponibles por la Azure Function y registrar los procesos en el servicio de Cosmos DB.

- **Azure Function (azfun-POC-IFIS-CR):** Es un servicio de computación sin servidor (serverless) que ofrece Microsoft Azure y que permite ejecutar pequeñas piezas de código o funciones en la nube sin tener que preocuparse por la infraestructura. La función se ejecuta solo cuando se activa por un evento (como una solicitud HTTP, un archivo nuevo en un Blob, un mensaje en una cola, etc.)
  Azure escala la función automáticamente dependiendo de la demanda.

Staging Area

- **Data lake storage (asapocifiscr):** Azure Data Lake Storage como solución de lago de datos, proporciona una opción rentable y altamente escalable para el análisis de macrodatos. Combina un sistema de archivos de alto rendimiento con una escala masiva y economía, siendo ideal para almacenar datos provenientes de la carga masiva documental, datos procesados por herramientas de ETL, y resultados de modelos de inteligencia artificial. Este almacenamiento será crucial para la disponibilidad de datos necesarios y que

el modelo pueda realizar consultas directamente sobre los documentos propios de IFISCAF, llevando un registro estructurado.

Procesamiento de lenguaje

- **Azure open AI (oai-POC-iDataFactory-CR-IFISCAF):** API de REST a potentes modelos de lenguaje de OpenAI, incluyendo GPT-4o y GPT-3.5-Turbo. Estos modelos, versátiles y eficaces, se pueden adaptar fácilmente a tareas específicas como generación de contenido, resumen, búsqueda semántica y traducción de lenguaje natural a código. La disponibilidad a través de API REST, SDK de Python y Azure OpenAI Studio proporciona flexibilidad en el uso de este servicio para enriquecer el procesamiento de lenguaje.
- **Datafactory (adf-POC-IFIS-CR):** actúa como un orquestador dentro de esta arquitectura. Es el servicio encargado de recibir las peticiones de extracción que realiza el usuario y ejecutar una serie de pipelines que garantizan que el proceso no entre en un estado de timeout ni se pierda su ejecución sin importar su duración. Este servicio se conecta directamente con las Azure Functions , Azure Databricks y Azure cosmos DB .
- **Azure Databricks (databricks-cr) :** El desarrollo de notebooks garantiza la versatilidad en los distintos escenarios en los que sea necesario extraer información de documentos. Estos notebooks fueron desarrollados usando SQL o PySpark para ser ejecutados bajo de manda o de manera programada por medio del servicio de Azure Databricks. Este servicio añade una capa muy importante de personalización y ajuste sobre la necesidad de negocio. Además de ser altamente integrable con la mayoría de los servicios Azure.
- **Azure Document Intelligence (di-POC-IFIS-CR):** es el servicio por excelencia en la extracción y reconocimiento de información de múltiples documentos, cabe aclarar que su funcionamiento se basa en la identificación de la posición (coordenadas) de la información a extraer. Es por esto que si la necesidad se basa en extraer información sobre documentos que tengan un mismo formato, Document Intelligence es la mejor opción, y bajo este escenario se trabaja de la mano con Azure Open AI para la extracción de información de las diferentes fuentes. Document Intelligence funcionaría como OCR, es decir se limitaría la extracción del texto del documento enviado, que sería usado después por Open IA.

Capa almacenamiento interacciones

- **Azure Cosmos DB (cd-poc-idatafactory-cr) :** Es una base de datos NoSQL y relacional totalmente administrada para el desarrollo de aplicaciones modernas, entre las que se incluyen; Inteligencia artificial, comercio digital, Internet de las cosas, administración de reservas y otros tipos de soluciones. Esta base de datos es implementada en la solución para almacenar los logs de las interacciones con la herramienta y tener una auditoria de la misma.

Consideraciones de seguridad y funcionalidad

- Se recomienda usar managed identity para realizar la comunicación entre los servicios desplegados, y desactivar el uso de shared keys.
- Se almacenar el código fuente desarrollado en Azure DevOps y generar pipelines tanto de CI como CD para garantizar la automatización del despliegue.

Costos asociados

A continuación, se detallan los posibles costos asociados a cada arquitectura, es importante mencionar que este es un estimado y que puede variar en cualquier momento.

Service type	Description	Estimated monthly cost
Storage Accounts	Block Blob Storage, General Purpose V2, Flat Namespace, LRS Redundancy, Hot Access Tier, 1,000 GB Capacity - Pay as you go, 10 x 10,000 Write operations, 10 x 10,000 List and Create Container Operations, 10 x 10,000 Read operations, 1 x 10,000 Other operations. 1,000 GB Data Retrieval, 1,000 GB Data Write, SFTP disabled	$19,44
App Service	Standard Tier; 1 S3 (4 Core(s), 7 GB RAM, 50 GB Storage) x 730 Hours; Linux OS; 0 SNI SSL Connections; 0 IP SSL Connections; 0 Custom Domains; 0 Standard SLL Certificates; 0 Wildcard SSL Certificates	$277,40

Azure Functions	Premium tier, Pay as you go, EP2: 2 Cores(s), 7 GB RAM, 250 GB Storage, 1 Pre-warmed instances, 1 Additional scaled out units	$583,71
Azure AI Document Intelligence	Azure Form Recognizer, Commitment Tier, Azure standard, Custom: Custom pages - 20,000 pages commitment tier and 52,000 overage pages	$1.944,00
Azure OpenAI Service	Language Models, Standard (On-Demand), GPT-4o-Regional-API-128K, 60,000 x 1,000 input tokens, 0 x 1,000 output tokens	$300,00
Azure Cosmos DB	Azure Cosmos DB for NoSQL (formerly Core), Serverless, Always-free quantity disabled, Single Region Write (Single-Master) - East US (Write Region), 100 million RUs, 0 GB transactional storage, 2 copies of periodic backup storage, Dedicated Gateway not enabled	$25,00
Azure Data Factory	Azure Data Factory V2 Type, Data Pipeline Service Type, Azure Integration Runtime: 100 Activity Run(s), 200 Data movement unit(s), 200 Pipeline activities, 200 Pipeline activities – External,	$151,05
Azure Databricks	All-Purpose Compute Workload, Premium Tier, 1 D32AV4 (32 vCPU(s), 128 GB RAM) x 730 Hours, Pay as you go, 6 DBU x 730 Hours	$3.530,28
Support		$0,00
Licensing Program	**Microsoft Customer Agreement (MCA)**	
Billing Account		
Billing Profile		
Total		**$6.830,88**

Referencias

- PageWriter-Msft. (s. f.). Azure Well-Architected Framework - Microsoft Azure Well-Architected Framework. Microsoft Learn. https://learn.microsoft.com/en-us/azure/well-architected/

- Zimmergren. (2025, 20 enero). Define your naming convention – Cloud Adoption Framework. Microsoft Learn. https://learn.microsoft.com/en us/azure/cloud-adoption-framework/ready/azure-best-practices/resource naming

- Chcomley. (s. f.). Azure DevOps documentation. Microsoft Learn. https://learn.microsoft.com/en-us/azure/devops/?view=azure-devops